

让风险进入可以识别、分级和验证的产品机制。

内容安全从具体场景出发，区分风险成因与影响，再为不同问题选择限制说明、风险提示、拒答或人工确认路径。

材料说明

依据实际项目中的内容安全工作方法脱敏重构。风险问题、模型回答、策略文本和测试结果均为合成信息，不包含内部规则、Prompt、知识库或客户资料。

01 / SENSITIVE

敏感内容

RISK SIGNAL

输入或回答可能涉及个人、业务或其他敏感信息。

PRODUCT JUDGEMENT 限制披露范围，必要时停止回答。

02 / HALLUCINATION

事实幻觉

RISK SIGNAL

模型可能虚构政策、文件、数据、部门职责或办理条件。

PRODUCT JUDGEMENT 要求依据约束，暴露不确定性并进入核对。

03 / UNCERTAINTY

知识不确定

RISK SIGNAL

知识缺失、过期、召回不足或证据无法支持完整结论。

PRODUCT JUDGEMENT 说明信息边界，提示补充依据或人工确认。

04 / AUTHORITY

越权回答

RISK SIGNAL

问题超出系统服务范围、模型权限或可判断边界。

PRODUCT JUDGEMENT 不代替有权主体作出结论，引导至合适渠道。

CONTENT SAFETY DEFENCE

输入检测

风险分类

回答策略

输出审核

安全回归

同一个模型，在不同风险下需要不同动作。

以下四个合成案例用于说明风险到策略的映射，不对应真实问题、政策或模型回答。

材料说明

依据实际项目中的内容安全工作方法脱敏重构。风险问题、模型回答、策略文本和测试结果均为合成信息，不包含内部规则、Prompt、知识库或客户资料。

CASE 01

敏感信息索取

SYNTHETIC INPUT	请求模型补充或推断未公开的个人信息。
RISK	信息泄露与不当推断
ACTION	限制披露 / 拒答
OUTPUT RULE	不复述、不推断，并说明可提供的信息范围。

CASE 02

政策依据不明

SYNTHETIC INPUT	要求引用一份无法确认存在的政策文件。
RISK	事实幻觉与虚构依据
ACTION	风险提示 / 核对
OUTPUT RULE	不生成文件名称和条款，提示核对正式来源。

CASE 03

知识不足仍需结论

SYNTHETIC INPUT	现有知识无法支持完整的办理条件判断。
RISK	知识缺失或召回不足
ACTION	限制说明 / 人工确认
OUTPUT RULE	说明已知范围和缺失信息，不用通用经验补齐。

CASE 04

要求代替有权主体判断

SYNTHETIC INPUT	请求模型直接作出资格、责任或审批结论。
RISK	超出模型权限与服务边界
ACTION	渠道引导 / 拒绝结论
OUTPUT RULE	提供一般信息并引导至有权部门，不代替正式判断。

安全策略也要检查漏放、误拦与相邻场景退化。

一次策略修改完成后，同时复测目标风险、正常相邻问题和历史 Bad Case，避免安全增强以牺牲正常可用性为代价。

材料说明

依据实际项目中的内容安全工作方法脱敏重构。风险问题、模型回答、策略文本和测试结果均为合成信息，不包含内部规则、Prompt、知识库或客户资料。

TEST SET COMPOSITION

测试集覆盖什么

- 01

目标风险

本次策略需要识别和处理的风险问题。
- 02

表达变体

同一意图的改写、隐含表达与多轮追问。
- 03

正常相邻

内容相似但应当正常回答的问题，用于检查误拦。
- 04

历史案例

此前发现并修复的安全 Bad Case。
- 05

跨场景回归

问答、公文与其他能力是否受到策略副作用影响。

ACCEPTANCE MATRIX / SYNTHETIC

同时验证安全与可用

该拦截时拦截

HARD

风险问题是否进入正确策略。

该回答时回答

USABLE

正常问题是否保持可用。

理由表达清楚

QUALITY

限制或拒答是否说明边界。

多轮保持一致

STABLE

追问后是否绕过既定策略。

BAD CASE → REGRESSION

记录失败

原因归类

调整策略

定向复测

全量回归

公开样张不设置虚构的统一通过阈值。真实工作中根据不同风险场景的验收要求判断是否进入 Bad Case 与复测。